

**Sistem Deteksi Hoaks Menggunakan Metode TF-IDF dan Algoritma
Machine Learning**



Anthonius Raffael Pangaribuan

A11.2024.15812

A11.4411

Program Studi Teknik Informatika

Universitas Dian Nuswantoro

2026

DAFTAR ISI

BAB I.....	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	1
BAB II.....	2
2.1 Analisis Dataset dan Representasi.....	2
2.1.1 Sumber Data	2
2.1.2 Representasi Data	2
2.2 Perancangan Pipeline Pembelajaran Mesin.....	2
2.3 Strategi Pemodelan dan Eksperimen.....	3
2.4 Rencana Deployment Model.....	3
BAB III	4
3.1 Timeline.....	4
3.2 Kesimpulan Rencana Kerja.....	5

BAB I

PENDAHULUAN

1.1 Latar Belakang

Penyebaran berita bohong (hoaks) di Indonesia, terutama yang berkaitan dengan isu politik dan pemerintahan, semakin tidak terkendali seiring dengan tingginya penggunaan media sosial dan aplikasi pesan instan. Masyarakat sering kali kesulitan membedakan antara artikel berita jurnalistik yang valid dengan narasi provokatif tak berdasar. Pengecekan fakta secara manual membutuhkan waktu dan literasi digital yang memadai. Oleh karena itu, diperlukan sebuah sistem otomatis berbasis Kecerdasan Buatan yang dapat membantu masyarakat awam mengklasifikasikan kebenaran suatu teks berita politik secara cepat dan akurat.

1.2 Rumusan Masalah

Berdasarkan latar belakang di atas, rumusan masalah dalam proyek ini adalah:

- Bagaimana membangun model *Machine Learning* yang mampu mengklasifikasikan teks berita politik berbahasa Indonesia ke dalam kategori "Hoaks" atau "Valid"?
- Bagaimana merancang antarmuka sistem yang memudahkan pengguna untuk menginputkan teks secara manual maupun mengekstrak teks langsung dari gambar tangkapan layar (*screenshot*) berita?

BAB II

METODOLOGI PENELITIAN

2.1 Analisis Dataset dan Representasi

2.1.1 Sumber Data

Proyek ini menggunakan dataset publik "Indonesian Fact and Hoax Political News" yang berisi kumpulan teks berita nasional. Data berlabel "Valid" bersumber dari portal media resmi berstandar jurnalistik (CNN Indonesia, Kompas, Tempo), sedangkan data berlabel "Hoaks" dihimpun dari arsip situs *fact-checking* TurnBackHoax.id.

2.1.2 Representasi Data

Data asli yang berbentuk teks narasi (*string*) tidak dapat diproses langsung oleh mesin. Oleh karena itu, teks direpresentasikan menjadi matriks angka matematis menggunakan metode pembobotan **TF-IDF** (*Term Frequency-Inverse Document Frequency*).

2.2 Perancangan Pipeline Pembelajaran Mesin

Alur pemrosesan (*pipeline*) sistem dirancang dengan tahapan berikut:

1. **Data Ingestion:** Menggabungkan *file* data mentah dari berbagai sumber menjadi satu *dataframe* utuh.
2. **Text Preprocessing:** Melakukan pembersihan teks menggunakan *Regular Expression* (Regex) untuk mengubah teks menjadi huruf kecil (*case folding*), menghapus tanda baca, angka, serta membuang baris data yang kosong (*missing values*).
3. **Feature Extraction:** Menerjemahkan teks bersih ke bentuk vector numerik menggunakan algoritma TF-IDF
4. **Model Training:** Melatih algoritma klasifikasi untuk membedakan pola kata hoaks dan valid.
5. **Prediction Output:** Mengeluarkan hasil klasifikasi biner.

2.3 Strategi Pemodelan dan Eksperimen

- **Algoritma Utama:** Model yang digunakan adalah **Logistic Regression** (Regresi Logistik). Pemilihan ini didasarkan pada efektivitas algoritma ini dalam menangani kasus klasifikasi biner (*Binary Classification*) pada data teks dengan ruang dimensi yang besar (hasil TF-IDF) secara cepat dan komputasi yang ringan.
- **Strategi Eksperimen:** Dataset akan dibagi menjadi data latih (*training data*) dan data uji (*testing data*). Evaluasi performa model akan diukur menggunakan metrik standar klasifikasi, seperti *Accuracy*. Selain itu, akan dilakukan eksperimen integrasi dengan **Tesseract OCR** (*Optical Character Recognition*) untuk mengekstraksi teks dari masukan berupa gambar.

2.4 Rencana Deployment Model

Model *Machine Learning* yang telah dilatih (*pre-trained model*) akan diekspor (disimpan) menggunakan *library* Joblib. Model tersebut kemudian akan diintegrasikan ke dalam antarmuka aplikasi web interaktif yang dibangun menggunakan *framework* **Streamlit**. Aplikasi ini akan di-*deploy* secara lokal (di dalam *localhost*) sehingga pengguna dapat langsung mengetikkan teks atau mengunggah gambar *screenshot* berita dan melihat hasil prediksinya melalui *web browser*.

BAB III

JADWAL PELAKSANAAN

3.1 Timeline

- Minggu 1: Studi Literatur dan Penyiapan Data
 1. Mengunduh dataset *Indonesian Fact and Hoax Political News* dari Kaggle.
 2. Melakukan *Data Ingestion* (menggabungkan dataset CNN, Kompas, Tempo, dan TurnBackHoax menggunakan *pandas*).
- Minggu 2: Pra-pemrosesan Data (Data Preprocessing)
 1. Membangun fungsi pembersihan teks
 2. Menerapkan *case folding* (huruf kecil) dan penghapusan tanda baca menggunakan *Regular Expression* (Regex).
 3. Membersihkan baris data yang kosong
- Minggu 3: Ekstraksi Fitur (Feature Extraction)
 1. Mengimplementasikan algoritma TF-IDF (*Term Frequency-Inverse Document Frequency*).
 2. Mengubah teks bahasa Indonesia yang sudah bersih menjadi matriks vektor numerik.
- Minggu 4: Pelatihan Model Machine Learning
 1. Membagi dataset menjadi data latih (*training data*) dan data uji (*testing data*).
 2. Melatih model klasifikasi menggunakan algoritma *Logistic Regression*.
- Minggu 5: Evaluasi dan Validasi Model
 1. Mengukur performa model menggunakan metrik akurasi (*Accuracy Score*).
 2. Menyimpan model yang sudah dilatih (ekspor) menggunakan *library* Joblib agar siap diintegrasikan.
- Minggu 6: Eksperimen Computer Vision (OCR)
 1. Mempelajari dan menginstal pustaka Tesseract OCR.
 2. Membangun skrip Python untuk mengekstrak teks dari gambar (*screenshot* berita) agar bisa dibaca oleh sistem.

- Minggu 7: Pengembangan Antarmuka (Deployment)
 1. Merancang antarmuka pengguna (UI) berbasis web menggunakan *framework* Streamlit.
 2. Menggabungkan fungsi Tesseract OCR dan model *Logistic Regression* ke dalam satu alur (*pipeline*) di Streamlit.
- Minggu 8: Pengujian Sistem dan Penyusunan Laporan (UAS)
 1. Melakukan uji coba menyeluruh (*End-to-End Testing*) dengan mengunggah gambar hoaks dan gambar berita valid.
 2. Melakukan perbaikan (*bug fixing*) jika ada *error*.

3.2 Kesimpulan Rencana Kerja

Berdasarkan seluruh perencanaan yang telah dipaparkan, proyek pembangunan sistem deteksi hoaks berita politik ini dirancang sebagai solusi sistematis untuk membantu masyarakat memverifikasi informasi secara mandiri. Dengan mengintegrasikan metode *Natural Language Processing* (NLP) untuk pengolahan teks, algoritma *Logistic Regression* untuk klasifikasi maknanya, serta teknologi Tesseract OCR untuk menangani masukan berupa gambar, diharapkan sistem ini dapat berjalan dengan akurat dan memiliki antarmuka yang ramah pengguna berbasis Streamlit. Rencana kerja yang terstruktur dalam *timeline* pelaksanaan akan menjadi acuan utama dalam pengembangan sistem agar implementasi penuh pada tahap Ujian Akhir Semester (UAS) dapat diselesaikan secara tepat waktu dan memenuhi standar akademis yang diharapkan.