

**SISTEM DETEKSI HOAKS MENGGUNAKAN METODE TF-IDF DAN
ALGORITMA MACHINE LEARNING**



Anthonius Raffael Pangaribuan

A11.2024.15812

A11.4404

Program Studi Teknik Informatika

Universitas Dian Nuswantoro

2026

DAFTAR ISI

BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Solusi.....	1
1.3 Tujuan.....	2
BAB II METODOLOGI	3
2.1 Akuisisi Data	3
2.2 Pra-pemrosesan Data (Preprocessing).....	4
2.3 Ekstraksi Fitur (TF-IDF)	4
2.4 Pembagian Dataset (<i>Data Splitting</i>).....	4
2.5 Pemodelan Eksperimen	4
BAB III HASIL DAN ANALISIS	5
3.1 Perbandingan Performa Algoritma.....	5
3.2 Analisis Detil Model Terbaik (Logistic Regression).....	5
3.3 Interpretasi dan Uji Coba Manual	6
BAB IV KESIMPULAN DAN REKOMENDASI.....	7
4.1 Kesimpulan.....	7
4.2 Rekomendasi Pengembangan.....	7

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi informasi yang pesat telah mengubah cara masyarakat mengonsumsi berita secara drastis. Di era digital ini, penyebaran informasi terjadi dalam hitungan detik melalui berbagai platform media sosial dan portal berita daring. Namun, kemudahan akses ini membawa tantangan krusial berupa maraknya penyebaran informasi palsu atau hoaks. Di Indonesia, narasi hoaks yang berkaitan dengan isu politik, pemerintahan, dan kebijakan nasional seringkali dimanfaatkan oleh pihak tidak bertanggung jawab untuk memanipulasi opini publik, menimbulkan keresahan, dan memicunya polarisasi di tengah masyarakat.

Upaya pengecekan fakta (*fact-checking*) secara manual oleh jurnalis maupun dewan pers membutuhkan waktu dan sumber daya yang tidak sedikit. Proses manual ini seringkali kalah cepat dengan eksponensialnya laju penyebaran hoaks itu sendiri. Oleh karena itu, diperlukan sebuah sistem komputasi otomatis yang mampu menganalisis dan mengklasifikasikan kebenaran suatu teks berita secara cepat guna membantu masyarakat menyaring informasi yang beredar.

1.2 Solusi

Sebagai solusi atas permasalahan tersebut, proyek ini mengembangkan sebuah aplikasi pendeteksi hoaks berbasis kecerdasan buatan (*Machine Learning*). Pemodelan dibangun memanfaatkan dataset publik *Indonesian Fact and Hoax Political News*, yang mencakup kompilasi berita valid dari portal berita resmi (seperti CNN Indonesia, Kompas, dan Tempo) serta arsip berita palsu dari situs *TurnBackHoax.id*.

Proyek ini mengimplementasikan teknik *Natural Language Processing* (NLP) menggunakan metode ekstraksi fitur *Term Frequency-Inverse Document Frequency* (TF-IDF) untuk menerjemahkan teks menjadi representasi numerik. Proses klasifikasi kemudian dilakukan menggunakan algoritma *Logistic Regression* sebagai model prediktif utama, yang juga dikomparasikan dengan model *Naive Bayes* untuk evaluasi performa.

1.3 Tujuan

Tujuan utama dari proyek ini adalah merancang, membangun, dan mengevaluasi model *Machine Learning* dengan tingkat akurasi yang tinggi dalam mendeteksi berita hoaks berbahasa Indonesia. Lebih jauh, model terbaik yang dihasilkan akan diintegrasikan (*deploy*) ke dalam antarmuka aplikasi web interaktif menggunakan *framework* Streamlit. Melalui aplikasi ini, diharapkan pengguna akhir (*end-user*) dapat dengan mudah melakukan verifikasi kredibilitas teks berita secara instan, menjadikan proyek ini sebagai bentuk implementasi nyata dari konsep komputasi cerdas dalam menyelesaikan permasalahan sosial sehari-hari.

BAB II

METODOLOGI

Metodologi yang digunakan dalam pengembangan sistem deteksi hoaks ini mengikuti *pipeline* standar proyek *Data Science* dan *Machine Learning*. Alur kerja dirancang secara sekuensial, dimulai dari pengumpulan data mentah, dilanjutkan dengan tahap pra-pemrosesan teks terpusat. Data yang telah bersih kemudian diubah menjadi vektor numerik melalui proses ekstraksi fitur, untuk selanjutnya dibagi menjadi set pelatihan dan pengujian. Tahap akhir melibatkan pelatihan algoritma klasifikasi dan evaluasi metrik secara komprehensif.



2.1 Akuisisi Data

Dataset yang digunakan diperoleh dari platform Kaggle dengan judul *Indonesian Fact and Hoax Political News*. Data mentah tersebut terdiri dari empat file berformat spreadsheet (.xlsx) dengan total volume data mencapai lebih dari 31.000 baris berita politik. Komposisi dataset meliputi:

- dataset_cnn_10k.xlsx (Diberi label target: **Valid**)
- dataset_kompas_4k.xlsx (Diberi label target: **Valid**)
- dataset_tempo_6k.xlsx (Diberi label target: **Valid**)
- dataset_turnbackhoax_10k.xlsx (Diberi label target: **Hoaks**)

2.2 Pra-pemrosesan Data (Preprocessing)

Untuk memastikan konsistensi dan membuang elemen noise pada teks, dilakukan pembersihan data secara modular memanfaatkan fungsi utilitas terpusat di dalam berkas `utils.py`. Tahapan pembersihan meliputi:

1. **Penanganan Nilai Kosong (*Missing Values*):** Menghapus baris data berita yang tidak memiliki konten teks pada kolom utama.
2. **Case Folding:** Mengubah seluruh karakter huruf di dalam teks menjadi huruf kecil (*lowercase*) agar tidak terjadi duplikasi makna akibat perbedaan kapitalisasi.
3. **Pembersihan Karakter (*Cleansing*):** Menggunakan teknik *Regular Expression* (Regex) untuk menghapus angka, tanda baca, spasi berlebih, serta simbol-simbol non-alfabet yang tidak memberikan kontribusi kontekstual pada model klasifikasi.

2.3 Ekstraksi Fitur (TF-IDF)

Teks berita yang telah bersih ditransformasikan ke dalam representasi vektor numerik menggunakan metode *Term Frequency-Inverse Document Frequency* (TF-IDF). Untuk menjaga efisiensi performa komputasi lokal dan mencegah *curse of dimensionality*, fitur dibatasi menggunakan parameter `max_features=5000`, yang berarti sistem hanya mengekstrak 5.000 kata paling penting dan berpengaruh di seluruh korpus teks berita.

2.4 Pembagian Dataset (*Data Splitting*)

Dataset yang telah diekstraksi fiturnya dibagi menjadi dua bagian dengan proporsi **80% untuk data latih (*Training Set*)** dan **20% untuk data uji (*Testing Set*)** menggunakan parameter pengunci acak `random_state=42` demi menjamin konsistensi reproduksibilitas eksperimen.

2.5 Pemodelan Eksperimen

Sesuai dengan rancangan penelitian, proses pelatihan membandingkan dua algoritma klasifikasi yang berbeda karakteristiknya, yaitu:

1. **Logistic Regression:** Algoritma linier yang bekerja dengan menghitung probabilitas keanggotaan kelas berbasis fungsi sigmoid, dikonfigurasi dengan batas iterasi maksimum `max_iter=1000`.
2. **Multinomial Naive Bayes:** Algoritma probabilistik berbasis Teorema Bayes yang sangat populer dan efisien dalam penambangan teks serta klasifikasi dokumen teks.

BAB III

HASIL DAN ANALISIS

Setelah proses pelatihan selesai diimplementasikan pada data uji (*testing set*), performa dari kedua algoritma diukur secara komprehensif menggunakan metrik *Accuracy*, *Precision*, *Recall*, dan *F1-Score*.

3.1 Perbandingan Performa Algoritma

Berdasarkan hasil pengujian eksperimen pada notebook pemodelan, berikut adalah tabel perbandingan performa metrik dari kedua model:

Algoritma Klasifikasi	Akurasi Utama	Precision (Macro Avg)	Recall (Macro Avg)	F1-Score (Macro Avg)
Logistic Regression	99.35%	0.99	0.99	0.99
Multinomial Naive Bayes	98.00%	0.98	0.98	0.98

3.2 Analisis Detil Model Terbaik (Logistic Regression)

Algoritma *Logistic Regression* terpilih sebagai model terbaik karena menghasilkan tingkat akurasi tertinggi sebesar **99.35%**. Hasil pengujian *Classification Report* secara mendalam menunjukkan visualisasi metrik performa per-label sebagai berikut:

- **Label Hoaks:** Memiliki nilai *Precision* sebesar 0.99 dan *Recall* sebesar 0.99, menunjukkan kemampuan model yang sangat presisi dalam mengidentifikasi berita palsu tanpa banyak salah tebak.
- **Label Valid:** Memiliki nilai *Precision* sebesar 0.99 dan *Recall* mencapai 1.00, membuktikan bahwa model hampir tidak pernah melewatkan berita yang bersumber dari portal berita resmi.

Untuk menguji stabilitas performa model ini secara akademis, dilakukan pengujian validasi silang **5-Fold Cross Validation**. Pengujian ini membagi data latih menjadi 5 bagian secara bergantian untuk melatih dan menguji model. Hasil pengujian menunjukkan rata-rata akurasi validasi yang sangat tinggi dan stabil, yakni mencapai **99.43%**. Angka rata-rata yang konsisten di atas 99% ini menjadi bukti ilmiah yang kuat bahwa model *Logistic Regression* yang dibangun bersifat *robust* (andal) dan terhindar dari indikasi *overfitting* (menghafal data latih).

3.3 Interpretasi dan Uji Coba Manual

Melalui berkas jurnal eksperimen 03_interpretation.ipynb, dilakukan proses memuat kembali (*loading*) objek model yang telah matang (.pkl) untuk melakukan pengujian prediksi langsung pada struktur teks buatan baru di luar dataset. Hasil simulasi menunjukkan:

- Teks narasi manipulatif tiruan terkait pembagian uang gratis berhasil diidentifikasi secara tepat oleh kecerdasan buatan dengan prediksi label: **HOAKS**.
- Teks formal terkait agenda regulasi lembaga negara berhasil diidentifikasi secara tepat dengan prediksi label: **VALID**.

BAB IV

KESIMPULAN DAN REKOMENDASI

4.1 Kesimpulan

Berdasarkan seluruh rangkaian tahapan *Capstone Project* yang telah dilaksanakan, dapat disimpulkan bahwa proyek akhir ini telah berhasil membangun sistem klasifikasi deteksi hoaks politik berbahasa Indonesia dengan performa yang sangat luar biasa. Penerapan kombinasi metode ekstraksi teks TF-IDF dengan pembatasan 5.000 fitur terbukti efisien dalam menyuplai informasi numerik yang kaya kepada algoritma komputasi.

Dari hasil komparasi eksperimen, algoritma *Logistic Regression* mengungguli *Multinomial Naive Bayes* dengan capaian akurasi akhir sebesar **99.35%** dan rata-rata validasi silang sebesar **99.43%**. Hasil akhir pemodelan yang matang ini telah berhasil diekspor menjadi berkas *pickle* (.pkl) dan siap diintegrasikan penuh ke antarmuka aplikasi web berbasis Streamlit guna memberikan kemudahan akses bagi masyarakat luas.

4.2 Rekomendasi Pengembangan

Meskipun sistem mencatatkan hasil metrik evaluasi yang mendekati sempurna, terdapat beberapa poin rekomendasi strategis demi pengembangan penelitian lanjutan di masa mendatang:

1. **Diversifikasi Domain Dataset:** Dataset pelatih sebaiknya diperluas ke ranah topik non-politik, seperti hoaks bertema kesehatan (medis), penipuan finansial digital, hiburan, dan isu global agar cakupan kemampuan deteksi aplikasi web menjadi lebih universal.
2. **Eksplorasi Algoritma Lanjutan:** Peneliti selanjutnya disarankan mencoba membandingkan model dasar ini dengan algoritma berbasis *Ensemble Learning* (seperti XGBoost atau Random Forest) atau pendekatan *Deep Learning* berbasis arsitektur *Transformers* (seperti IndoBERT) untuk menganalisis struktur kalimat kontekstual yang jauh lebih kompleks.
3. **Optimalisasi Fitur Tambahan:** Menambahkan kamus kata baku bahasa Indonesia atau proses *stemming* (mengubah kata berimbuhan menjadi kata dasar) pada berkas utilitas pra-pemrosesan data untuk memperkecil variasi kata noise.

REFERENSI

Kaggle. (2023). *Indonesian Fact and Hoax Political News*. Diakses dari <https://www.kaggle.com/datasets/linkgish/indonesian-fact-and-hoax-political-news/data>

Scikit-learn Developers. (2023). *Scikit-learn: Machine Learning in Python (TfidfVectorizer & Logistic Regression)*. Diakses dari <https://scikit-learn.org/>

Streamlit Inc. (2024). *Streamlit Documentation: The fastest way to build and share data apps*. Diakses dari <https://docs.streamlit.io/>